

北京邮电大学

本科毕业设计（论文）



题目：基于时空特征融合与稀疏表示的 GNSS NLOS 识别方法研究

姓 名 雷 操

学 院 电子工程学院

专 业 电子信息科学与技术

班 级 2022211201

学 号 2022210938

指导教师 孙 源

2026 年 5 月

北 京 邮 电 大 学

本科毕业设计（论文）诚信声明

本人声明所呈交的毕业设计（论文），题目《基于时空特征融合与稀疏表示的 GNSS NLOS 识别方法研究》是本人在指导教师的指导下，独立进行研究工作所取得的成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京邮电大学或其他教育机构的学位或证书而使用过的材料。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解并同意北京邮电大学有关保留、使用学位论文的规定，即：北京邮电大学拥有以下关于学位论文的无偿使用权，具体包括：学校有权保留并向国家有关部门或机构送交学位论文，有权允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，有权允许采用影印、缩印或其它复制手段保存。汇编学位论文，将学位论文的全部或部分内容编入有关数据库进行检索。（保密的学位论文在解密后遵守此规定）

本人签名：_____ 日期：_____

导师签名：_____ 日期：_____

基于时空特征融合和稀疏表示的 GNSS NLOS 识别方法研究

摘 要

全球导航卫星系统 (GNSS) 在城市复杂环境中容易受到建筑物反射影响, 产生非视距 (Non-Line-of-Sight, NLOS) 传播问题, 导致定位误差大幅增加。本文提出一种基于时空特征融合和稀疏表示的 GNSS NLOS 识别模型 (Spatiotemporal Cross-Attention Model, STCA)。

该模型采用时空双通道特征提取架构: 空间通道捕获同一时刻多颗可见卫星的分布特征, 时间通道追踪单颗卫星在连续多个历元的信号演化趋势。通过交叉注意力模块, 使空间特征与时间特征在嵌入空间进行双向交互, 自动学习不同卫星、不同时刻特征的重要性权重。同时引入稀疏表示层, 迫使模型学习更具判别性的紧凑特征表示。

实验结果表明, 在内域场景下, 模型准确率达到 73.89%, 训练损失收敛至 0.6273。消融实验验证了各模块的有效性, 时间窗口大小为 10 时性能最优。

关键词 GNSS NLOS 识别 时空注意力 稀疏表示 深度学习

Research on GNSS NLOS Identification via Spatiotemporal Feature Fusion and Sparse Representation

ABSTRACT

Global Navigation Satellite System (GNSS) is susceptible to Non-Line-of-Sight (NLOS) propagation in urban complex environments due to signal reflection from buildings, resulting in significant positioning errors. This paper proposes a Spatiotemporal Cross-Attention (STCA) model for GNSS NLOS identification via spatiotemporal feature fusion and sparse representation.

The model employs a dual-channel architecture: a spatial channel captures the distribution characteristics of multiple visible satellites at the same epoch, while a temporal channel tracks the signal evolution of a single satellite across consecutive epochs. Through a cross-attention module, spatial and temporal features interact bidirectionally in the embedding space, automatically learning the importance weights of features from different satellites and epochs. A sparse representation layer is introduced to force the model to learn more discriminative and compact feature representations.

Experimental results show that in the indomain scenario, the model achieves an accuracy of 73.89% with training loss converging to 0.6273. Ablation studies verify the effectiveness of each module, and the optimal time window size is 10 epochs.

KEY WORDS GNSS NLOS detection spatiotemporal attention sparse representation deep learning

目 录

第一章 引言	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.3 技术挑战分析	2
1.4 研究目标与主要贡献	2
1.5 论文章节安排	3
第二章 相关理论与技术基础	4
2.1 深度学习基础	4
2.1.1 神经网络基本原理	4
2.1.2 反向传播与优化算法	4
2.2 注意力机制	5
2.2.1 自注意力原理	5
2.2.2 Transformer 架构	5
2.3 序列建模方法	5
2.3.1 RNN 与 LSTM 原理	5
2.3.2 双向 LSTM	6
2.4 稀疏表示理论	7
2.4.1 稀疏性概念	7
2.4.2 稀疏约束方法	7
2.5 GNSS 定位原理	7
2.5.1 伪距测量原理	7
2.5.2 NLOS 误差产生机制	8
2.6 本章小结	8
第三章 需求分析与总体设计	9
3.1 功能需求分析	9
3.2 性能指标定义	9
3.3 系统总体架构	9
3.4 技术选型	10
3.5 开发环境配置	10
3.6 本章小结	11

第四章 数据预处理系统设计	12
4.1 原始数据格式与分析	12
4.2 数据清洗与过滤	12
4.2.1 卫星高度角约束	13
4.2.2 C/N0 有效范围过滤	13
4.2.3 3σ 异常值剔除	13
4.3 数据集划分策略	13
4.3.1 内域划分 (indomain)	13
4.3.2 外域划分 (outdomain)	13
4.4 时间窗口构建	14
4.5 特征标准化	14
4.6 数据探索性分析	15
4.6.1 类别分布分析	15
4.6.2 特征相关性分析	15
4.7 本章小结	15
第五章 STCA 核心算法设计	16
5.1 模型总体架构	16
5.2 空间编码器设计	16
5.3 时序编码器设计	17
5.4 交叉注意力融合模块	17
5.5 稀疏表示层设计	18
5.6 分类器与损失函数	18
5.7 中期检查问题的改进设计	18
5.7.1 针对过拟合问题	18
5.7.2 针对时序模块利用率不足	19
5.7.3 针对类别判断偏向性	19
5.8 模型复杂度分析	19
5.8.1 参数量分析	19
5.8.2 计算复杂度分析	19
5.9 算法伪代码	20
5.10 本章小结	20
第六章 系统实现与训练优化	21
6.1 开发环境与依赖配置	21
6.2 数据加载模块实现	21
6.3 模型实现细节	21

6.4	训练器实现	21
6.5	训练优化策略	22
6.6	超参数确定实验	22
6.7	模块实现细节	23
6.7.1	空间编码器模块	23
6.7.2	时序编码器模块	23
6.7.3	交叉注意力模块	24
6.8	训练流程图	24
6.9	超参数调优过程	24
6.10	本章小结	25
第七章	实验验证与分析	26
7.1	实验设置	26
7.1.1	硬件环境	26
7.1.2	超参数配置	26
7.2	内域泛化结果	26
7.2.1	训练过程分析	26
7.2.2	混淆矩阵分析	27
7.2.3	ROC 曲线与 PR 曲线	27
7.2.4	定量评估指标	27
7.3	外域泛化结果	27
7.3.1	训练曲线对比	27
7.3.2	性能对比分析	27
7.3.3	混淆矩阵与 ROC/PR 曲线	28
7.4	消融实验	28
7.4.1	时间窗口大小敏感性分析	28
7.4.2	模块消融实验	29
7.5	本章小结	29
7.6	对比实验	30
7.6.1	基线方法	30
7.6.2	对比结果	30
7.7	失败案例分析	30
7.7.1	典型错误样本	30
7.7.2	错误原因分析	31
7.8	统计显著性检验	31
7.8.1	检验方法	31

7.8.2 检验结果	31
7.9 实验可复现性说明	32
7.10 本章小结	32
第八章 总结与展望	33
8.1 工作总结	33
8.2 存在不足与未来方向	33
8.3 主要创新点	33
8.4 研究局限	34
8.5 未来研究方向	34
8.6 结语	35
8.7 本章小结	35
参考文献	36
致谢	37

第一章 引言

1.1 研究背景与意义

全球导航卫星系统（Global Navigation Satellite System, GNSS）已在城市规划、交通管理、灾害监测、精准农业等领域得到广泛应用。随着智慧城市和自动驾驶技术的发展，用户对定位服务的精度与可靠性提出了更高要求。然而，在城市峡谷、密集建筑群等复杂场景中，GNSS 信号传播路径易受高层建筑遮挡与反射影响，产生严重的多径效应和非视距（Non-Line-of-Sight, NLOS）传播问题。研究表明，NLOS 信号可导致伪距测量误差达数十米甚至上百米，使单点定位误差远超可接受范围，严重制约了高精度定位服务在城市环境中的可用性。

GNSS 接收机传统上采用最小二乘法或卡尔曼滤波进行位置解算，其基本假设是所有可见卫星信号均为视距（Line-of-Sight, LOS）传播。当该假设被 NLOS 信号破坏时，定位解算将产生系统性偏差。因此，准确识别并剔除或降权处理 NLOS 信号，成为提升 GNSS 定位性能的关键前提。通过有效的 NLOS 检测与抑制，可在不增加硬件成本的前提下显著改善定位精度与系统可用性，具有重要的理论意义与工程应用价值。

1.2 国内外研究现状

围绕 GNSS NLOS 信号识别问题，国内外学者已开展大量研究，现有方法可归纳为以下四类：

第一类为阈值判别法。该方法基于载噪比（C/N0）、信号强度、伪距残差等单一或多个观测量的固定阈值进行 LOS/NLOS 分类。其优势在于实现简单、计算开销低，可直接嵌入接收机固件。然而，阈值选取高度依赖经验，难以适应不同城市环境、天气条件及接收机型号的变化，泛化能力有限。

第二类为 3D 模型辅助法。利用城市三维建筑模型与卫星星历，通过几何可见性分析预判信号传播路径是否被遮挡。该类方法物理意义明确、判别精度高，但依赖详细且实时更新的城市地理信息系统（GIS）数据，部署成本高昂，难以在中小城市或发展中国家推广。

第三类为传统机器学习方法。以支持向量机（SVM）、随机森林（Random Forest）、梯度提升树（GBDT）等为代表，可融合载噪比、卫星高度角、方位角、伪距残差等多维特征进行分类。相比阈值法，机器学习方法具备更强的非线性建模能力，但仍依赖人工特征工程，特征选取与组合策略对最终性能影响显著，且难以捕捉特征间的时空耦合关系。

第四类为深度学习方法。近年来，全连接神经网络（DNN）、长短期记忆网络（LSTM）、Transformer 等模型被引入 NLOS 识别任务。深度学习方法可自动从原始观测数据中提取判别性特征，避免繁琐的手工特征设计，在多个公开数据集上取得优异性能。然而，现有深度学习模型普遍存在可解释性弱、对输入维度固定化假设过强、难以同时建模卫

星空间分布与信号时序演化等问题，制约了其在实际系统中的进一步应用。

表 1-1 对比了上述四类方法的优缺点。

表 1-1 GNSS NLOS 识别方法对比

方法	优点	缺点	适用场景
阈值判别法	实现简单、计算开销低	泛化能力差、依赖经验	固定场景快速部署
3D 模型辅助法	物理意义明确、精度高	依赖 GIS 数据、成本高	智慧城市数字孪生
传统机器学习	非线性建模、可解释性较好	依赖特征工程	中小规模数据集
深度学习	自动特征提取、性能优异	数据需求大、可解释性弱	大规模数据集

1.3 技术挑战分析

GNSS NLOS 信号识别面临以下技术挑战：

（1）多径效应与 NLOS 的区分困难。多径效应（Multipath）与 NLOS 传播均会导致伪距测量误差，但两者的物理机制不同：多径是直射信号与反射信号的叠加干涉，NLOS 是纯反射信号传播。在实际接收环境中，两者往往同时存在，难以严格区分。

（2）城市环境复杂性。不同城市的建筑物密度、高度分布、街道走向差异显著，导致 NLOS 信号的统计特性存在地域差异。在一个地点训练的模型，直接部署到另一地点时性能可能显著下降。

（3）卫星运动的时变性。卫星相对于接收机的位置不断变化，导致同一地点的 NLOS 模式随时间变化。例如，正午时刻被建筑物遮挡的卫星，可能在傍晚时刻变为 LOS 传播。

（4）类别不平衡问题。在开阔场景中，LOS 信号占主导地位，NLOS 样本占比可能低于 20%。类别不平衡会导致模型倾向于预测多数类，降低对 NLOS 信号的检出率。

（5）实时性要求。车载导航等应用场景要求低延迟的定位解算，NLOS 识别模型需在毫秒级时间内完成推理，对模型复杂度提出约束。

1.4 研究目标与主要贡献

针对现有方法的局限性，本文提出一种基于时空特征融合与稀疏表示的 GNSS NLOS 识别模型（Spatiotemporal Cross-Attention Model, STCA）。该模型借鉴 Zeng 等人（2024）提出的时空交叉注意力架构，结合 GNSS 信号传播的物理特性进行针对性改进。本文的主要研究目标与贡献如下：

（1）设计时空双通道特征提取架构。针对 GNSS 观测数据的固有特性，构建空间输入通道与时间输入通道：空间通道捕获同一时刻多颗可见卫星的分布特征（高度角、方位角、载噪比、伪距残差），时间通道追踪单颗卫星在连续多个历元的信号演化趋势。双通道设计使模型能够同时利用空间分集与时间相关性信息。

（2）引入交叉注意力机制实现时空特征融合。通过交叉注意力模块，使空间特征与时间特征在嵌入空间进行双向交互，自动学习不同卫星、不同时刻特征的重要性权重，避免简单拼接或加权平均导致的信息损失。

（3）采用稀疏表示层增强特征判别能力。在分类器前引入稀疏性约束，迫使模型学习更具判别性的紧凑特征表示，提升对噪声与异常值的鲁棒性，同时增强模型的可解释性。

（4）完成系统性实验验证与消融分析。在内域（训练集与测试集来自相同地理位置）与外域（跨地理位置泛化）两种场景下评估模型性能，验证模型的泛化能力。通过消融实验定量分析各功能模块对最终性能的贡献，为后续研究提供参考。

1.5 论文章节安排

本文共分为八章，各章内容安排如下：

第1章引言：阐述 GNSS NLOS 识别问题的研究背景与实际意义，系统综述国内外相关研究进展，概述本文的主要研究目标与技术贡献，并介绍论文整体结构。

第2章相关理论与技术基础：介绍深度学习基础、注意力机制、序列建模方法、稀疏表示理论以及 GNSS 定位原理，为后续章节奠定理论基础。

第3章需求分析与总体设计：从系统工程角度定义 NLOS 识别系统的功能需求与性能指标，介绍总体技术架构、开发环境选型与实验数据说明。

第4章数据预处理系统设计：详述原始 GNSS 观测数据的清洗策略、数据集划分方法（内域模式与外域模式）、时间窗口构建逻辑与特征标准化流程。

第5章 STCA 核心算法设计：完整阐述模型架构，包括空间编码器、时间编码器、交叉注意力融合模块、稀疏表示层与二分类器的设计原理与数学表述。

第6章系统实现与训练优化：介绍开发环境配置、各功能模块的代码实现细节、训练策略与超参数调优过程。

第7章实验验证与分析：展示内域与外域场景下的实验结果，与基线方法进行对比分析，完成消融实验验证各模块有效性。

第8章总结与展望：总结全文研究工作与创新点，客观分析当前方法的局限性，展望未来可能的研究方向。

第二章 相关理论与技术基础

2.1 深度学习基础

2.1.1 神经网络基本原理

人工神经网络（Artificial Neural Network, ANN）是深度学习的基础模型，灵感来源于生物神经元的的信息处理机制。一个典型的神经元接收多个输入信号 $x_1, x_2, \dots, x_n$ ，通过加权求和并经过非线性激活函数产生输出：

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right) \quad \text{式 (2-1)}$$

其中 w_i 为连接权重， b 为偏置项， $f(\cdot)$ 为激活函数。常用的激活函数包括 ReLU (Rectified Linear Unit)、Sigmoid 和 Tanh 等。

多层神经网络通过堆叠多个神经元层形成深层结构，能够学习输入数据的层次化特征表示。设第 l 层的输出为：

$$\mathbf{h}^{(l)} = f(\mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}) \quad \text{式 (2-2)}$$

其中 $\mathbf{W}^{(l)}$ 为权重矩阵， $\mathbf{b}^{(l)}$ 为偏置向量， $\mathbf{h}^{(0)}$ 为输入层。

2.1.2 反向传播与优化算法

神经网络通过反向传播算法（Backpropagation）进行训练。给定损失函数 $\mathcal{L}$ ，利用链式法则计算梯度：

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}^{(L)}} \cdot \prod_{k=l}^{L-1} \frac{\partial \mathbf{h}^{(k+1)}}{\partial \mathbf{h}^{(k)}} \cdot \frac{\partial \mathbf{h}^{(l)}}{\partial \mathbf{W}^{(l)}} \quad \text{式 (2-3)}$$

参数更新采用梯度下降法：

$$\mathbf{W}^{(l)} \leftarrow \mathbf{W}^{(l)} - \eta \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} \quad \text{式 (2-4)}$$

其中 η 为学习率。本研究采用 Adam 优化器，结合动量法和自适应学习率的优点，收敛速度更快且对超参数不敏感。

2.2 注意力机制

2.2.1 自注意力原理

注意力机制（Attention Mechanism）源于人类视觉系统的选择性关注特性。在深度学习中，注意力机制允许模型动态地关注输入序列中的重要部分。

自注意力（Self-Attention）机制通过计算输入序列内部各位置之间的相关性来实现信息聚合。给定输入序列 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N]$ ，自注意力计算过程如下：

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V \quad \text{式 (2-5)}$$

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V} \quad \text{式 (2-6)}$$

其中 $\mathbf{Q}$ 、 $\mathbf{K}$ 、 $\mathbf{V}$ 分别为查询（Query）、键（Key）、值（Value）矩阵， d_k 为缩放因子，用于防止点积过大导致梯度消失。

2.2.2 Transformer 架构

Transformer 是完全基于注意力机制的序列建模架构，摒弃了传统的循环和卷积结构。其核心组件包括：

（1）多头注意力（Multi-Head Attention）：并行执行多个注意力操作，捕捉不同子空间的特征：

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad \text{式 (2-7)}$$

其中 $\text{head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V)$ 。

（2）位置前馈网络（Position-wise Feed-Forward Network）：对每个位置独立应用两层全连接变换：

$$\text{FFN}(\mathbf{x}) = \text{ReLU}(\mathbf{x}\mathbf{W}_1 + \mathbf{b}_1) \mathbf{W}_2 + \mathbf{b}_2 \quad \text{式 (2-8)}$$

（3）层归一化与残差连接：加速训练收敛并缓解梯度消失问题。

2.3 序列建模方法

2.3.1 RNN 与 LSTM 原理

循环神经网络（Recurrent Neural Network, RNN）通过引入隐藏状态 $\mathbf{h}_t$ 来建模序列数据的时间依赖性：

$$\mathbf{h}_t = \tanh(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h) \quad \text{式 (2-9)}$$

然而，标准 RNN 存在梯度消失问题，难以捕捉长程依赖关系。长短期记忆网络（Long Short-Term Memory, LSTM）通过门控机制有效解决了这一问题。

LSTM 单元包含三个门控结构：

(1) 遗忘门：控制从上一时刻单元状态中遗忘的信息量

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad \text{式 (2-10)}$$

(2) 输入门：控制当前时刻新信息的写入量

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad \text{式 (2-11)}$$

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_C \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \quad \text{式 (2-12)}$$

(3) 输出门：控制单元状态的输出信息

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad \text{式 (2-13)}$$

单元状态和隐藏状态的更新公式为：

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t \quad \text{式 (2-14)}$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t) \quad \text{式 (2-15)}$$

2.3.2 双向 LSTM

双向 LSTM（Bi-directional LSTM, BiLSTM）通过同时从正向和反向两个方向处理序列，能够利用过去和未来的上下文信息：

$$\overrightarrow{\mathbf{h}}_t = \text{LSTM}_{\text{fwd}}(\mathbf{x}_t, \overrightarrow{\mathbf{h}}_{t-1}) \quad \text{式 (2-16)}$$

$$\overleftarrow{\mathbf{h}}_t = \text{LSTM}_{\text{bwd}}(\mathbf{x}_t, \overleftarrow{\mathbf{h}}_{t+1}) \quad \text{式 (2-17)}$$

$$\mathbf{h}_t = [\overrightarrow{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t] \quad \text{式 (2-18)}$$

双向 LSTM 在需要利用完整上下文信息的任务中表现优异，如序列标注、文本分类等。

2.4 稀疏表示理论

2.4.1 稀疏性概念

稀疏表示（Sparse Representation）是指用少量非零系数的线性组合来表示信号的表示方法。其数学形式为：

$$\mathbf{y} = \mathbf{D}\mathbf{x}, \quad \|\mathbf{x}\|_0 \leq k \quad \text{式 (2-19)}$$

其中 $\mathbf{D}$ 为字典矩阵， $\mathbf{x}$ 为稀疏系数向量， $\|\cdot\|_0$ 为 L_0 范数（非零元素个数）， k 为稀疏度。

稀疏表示在深度学习中具有以下优势：

- （1）提高特征判别性：稀疏激活迫使模型学习更具区分度的特征；
- （2）降低计算复杂度：稀疏矩阵运算可大幅减少计算量；
- （3）增强模型可解释性：稀疏表示更易于理解和分析；
- （4）抑制过拟合：稀疏性约束起到正则化作用。

2.4.2 稀疏约束方法

实现稀疏表示的主要方法包括：

- （1） L_1 正则化：在损失函数中添加 L_1 范数惩罚项

$$\mathcal{L}_{total} = \mathcal{L}_{task} + \lambda \|\mathbf{x}\|_1 \quad \text{式 (2-20)}$$

- （2）ReLU 激活函数： $\text{ReLU}(x) = \max(0, x)$ ，天然产生稀疏激活
- （3）K-sparse 自编码器：仅保留激活值最大的 k 个神经元
- （4）Dropout：训练阶段随机屏蔽部分神经元

2.5 GNSS 定位原理

2.5.1 伪距测量原理

全球导航卫星系统（GNSS）通过测量卫星信号的传播时间来计算接收机与卫星之间的距离（伪距）。伪距观测方程为：

$$P = \rho + c(dt_r - dt^s) + I + T + \varepsilon_P \quad \text{式 (2-21)}$$

其中：

- P ：测量伪距（单位：米）
- ρ ：卫星与接收机的几何距离

- c : 光速
- dt_r : 接收机钟差
- dt^s : 卫星钟差
- I : 电离层延迟
- T : 对流层延迟
- ε_P : 测量噪声与多路径误差

至少需要 4 颗卫星的伪距观测值才能解算接收机的三维位置和钟差。

2.5.2 NLOS 误差产生机制

在城市峡谷等复杂环境中，GNSS 信号可能被建筑物遮挡，经反射或衍射后到达接收机，形成非视距（NLOS）传播。NLOS 信号的传播路径为：

$$d_{NLOS} = d_{LOS} + \Delta d_{reflection} \quad \text{式 (2-22)}$$

其中 $\Delta d_{reflection}$ 为反射引起的额外路径长度，通常为正值。

NLOS 误差对伪距测量的影响为：

$$P_{NLOS} = P_{LOS} + \varepsilon_{NLOS} \quad \text{式 (2-23)}$$

其中 ε_{NLOS} 可达数十米甚至上百米，严重影响定位精度。因此，在进行位置解算前，识别并剔除 NLOS 信号是提高城市环境定位精度的关键步骤。

2.6 本章小结

本章系统介绍了 STCA 模型所依赖的基础理论。深度学习基础部分阐述了神经网络的基本原理和反向传播算法。注意力机制部分详细讲解了自注意力和 Transformer 架构。序列建模部分分析了 RNN 与 LSTM 的门控机制及双向 LSTM 的优势。稀疏表示理论部分讨论了稀疏性的概念、优势与实现方法。GNSS 定位原理部分介绍了伪距测量原理和 NLOS 误差的产生机制，为后续章节的模型设计奠定了理论基础。

第三章 需求分析与总体设计

3.1 功能需求分析

本研究需实现以下核心功能：

- (1) NLOS/LOS 二分类。接收 GNSS 观测数据，输出视距或非视距的判决结果。
- (2) 内域泛化验证。在同一测点的数据划分下评估模型性能，检验模型对已知场景的识别能力。
- (3) 外域泛化验证。采用跨测点划分策略，验证模型在未知场景中的适应能力。
- (4) 模型训练与保存。支持多 epoch 训练，自动保存验证性能最优的模型权重。
- (5) 实验结果可视化。生成混淆矩阵、ROC 曲线、PR 曲线、训练历史等图表。

3.2 性能指标定义

采用以下指标评估分类性能：

- 准确率 (Accuracy): $(TP + TN)/(TP + TN + FP + FN)$
- 精确率 (Precision): $TP/(TP + FP)$
- 召回率 (Recall): $TP/(TP + FN)$
- F1 分数: $2 \times P \times R/(P + R)$
- ROC 曲线下面积 (ROC-AUC)
- PR 曲线下面积 (PR-AUC)

其中，TP、TN、FP、FN 分别表示真正例、真负例、假正例、假负例的样本数量。

对于 NLOS 检测任务，召回率（检出率）比精确率更为关键：漏检 NLOS 信号会在定位解算中引入较大误差，而误检 LOS 信号仅减少可用卫星数量。

3.3 系统总体架构

系统由数据预处理、模型训练、评估可视化三部分组成：

- (1) 数据预处理：CSV 原始数据读取、清洗、时间窗口构建、标准化、NPZ 格式保存。
- (2) 模型训练：STCA 模型前向传播、反向传播、参数更新、模型保存。
- (3) 评估可视化：混淆矩阵、ROC/PR 曲线、训练历史绘制。

系统工作流程如下：

1. 从 CSV 文件读取原始 GNSS 观测数据

2. 执行数据清洗与过滤，剔除异常值
3. 构建时间窗口样本
4. 进行特征标准化处理
5. 保存为 NPZ 格式供训练使用
6. 训练 STCA 模型并保存最佳权重
7. 在测试集上评估模型性能
8. 生成可视化结果

3.4 技术选型

本系统的技术选型如下：

（1）深度学习框架：PyTorch 2.x。PyTorch 具有动态计算图、易于调试、社区活跃等优点，适合快速原型开发与实验迭代。

（2）数据处理库：NumPy。NumPy 提供高效的数组操作与线性代数运算，是 Python 科学计算的基础库。

（3）可视化工具：Matplotlib。Matplotlib 支持多种图表类型，可生成出版级质量的图像，满足论文插图需求。

（4）文档撰写： $\text{\LaTeX}$ 。 $\text{\LaTeX}$ 是学术界广泛使用的排版系统，尤其适合含有大量数学公式的科技文档。

3.5 开发环境配置

开发环境配置如表 3-1 所示。

表 3-1 开发环境配置

组件	版本/配置
操作系统	Windows 11 / Linux
Python	3.9+
PyTorch	2.0+
CUDA	11.8
NumPy	1.24+
Matplotlib	3.7+
Scikit-learn	1.2+

3.6 本章小结

本章从系统工程角度定义了 GNSS NLOS 识别系统的功能需求与性能指标。功能需求包括 NLOS/LOS 二分类、内域泛化验证、外域泛化验证、模型训练与保存、实验结果可视化。性能指标采用准确率、精确率、召回率、F1 分数、ROC-AUC、PR-AUC 等分类任务标准指标。系统架构由数据预处理、模型训练、评估可视化三部分组成。技术选型采用 PyTorch 深度学习框架、NumPy 数据处理库、Matplotlib 可视化工具和 LaTeX 文档排版系统。

第四章 数据预处理系统设计

数据预处理是 GNSS NLOS 信号识别任务的基础环节。原始 GNSS 观测数据包含多种噪声和误差源，直接使用可能导致模型学习到虚假关联。本章介绍从原始观测到模型输入的完整数据流水线设计，包括数据清洗、数据集划分、时序样本构建和特征标准化四个关键环节。

4.1 原始数据格式与分析

实验数据来自 7 个不同测点的静态采集实验。每个测点在固定位置连续观测数小时，采样频率为 1 Hz。每个历元的观测数据包含 4 维特征：

1. **载噪比 (C/N0)**: 单位 dB-Hz，反映接收信号的信噪比。LOS 信号通常具有较高的 C/N0 值 (40-50 dB-Hz)，而 NLOS 信号由于反射或衍射导致能量损失，C/N0 值偏低。
2. **高度角 (Elevation)**: 单位度，表示卫星相对于当地地平线的仰角。低高度角卫星信号传播路径更长，受大气延迟和多路径效应影响更显著。
3. **方位角 (Azimuth)**: 单位度，表示卫星相对于正北方向的水平角。在城市峡谷环境中，特定方位角的卫星信号更容易受到建筑物遮挡。
4. **伪距残差 (Pseudorange Residual)**: 单位米，定义为测量伪距与几何距离的差值。NLOS 信号由于传播路径延长，伪距残差通常为正值且数值较大。

标签定义：LOS 信号标记为 0（视距信号），NLOS 信号标记为 1（非视距信号）。标签由高精度参考位置和卫星星历计算得到的几何关系确定。

表 4-1 汇总了各特征的物理意义和典型取值范围。

表 4-1 GNSS 观测特征说明

特征	物理意义	单位	典型范围
C/N0	信号强度	dB-Hz	25-50
高度角	卫星仰角	度	0-90
方位角	卫星水平角	度	0-360
伪距残差	测量误差	米	-5-50

4.2 数据清洗与过滤

原始观测数据包含粗差和无效观测，需经清洗后方可使用。本研究采用三级过滤策略：

4.2.1 卫星高度角约束

剔除高度角低于 5° 的卫星观测。低仰角卫星信号传播路径穿过更厚的大气层，受电离层和对流层延迟影响显著，且更容易发生多路径反射。保留 5° 以上卫星可减少大气误差对模型的干扰。

4.2.2 C/N0 有效范围过滤

剔除载噪比异常值： $C/N_0 < 20 \text{ dB-Hz}$ 或 $C/N_0 > 50 \text{ dB-Hz}$ 的观测予以剔除。低于 20 dB-Hz 的信号通常已失锁，高于 50 dB-Hz 则可能为接收机异常。

4.2.3 3σ 异常值剔除

对每个特征采用 3σ 原则去除统计异常值。具体而言，对每个测点分别计算各特征的均值 μ 和标准差 σ ，剔除超出 $[\mu - 3\sigma, \mu + 3\sigma]$ 范围的观测。该方法假设特征近似服从正态分布，可有效剔除离群点。

上述过滤步骤按顺序执行，每步过滤后记录剔除比例，用于数据质量评估。

4.3 数据集划分策略

为全面评估模型性能，本研究设计两种数据集划分策略：内域划分用于评估同场景性能，外域划分用于评估跨场景泛化能力。

4.3.1 内域划分 (indomain)

内域划分采用测点内独立划分策略。每个测点的数据按时间顺序切分，70% 作为训练集，15% 作为验证集，15% 作为测试集。划分比例近似为 7:1.5:1.5。

该策略假设训练集和测试集来自同一分布，用于验证模型在已知场景下的拟合能力。由于同一测点的环境特征（建筑物布局、遮挡模式）相对稳定，内域测试通常能获得较高的识别准确率。

4.3.2 外域划分 (outdomain)

外域划分采用跨测点划分策略。7 个测点按 4:1:2 的比例分配：4 个测点用于训练集，1 个测点用于验证集，2 个测点用于测试集。

该策略模拟真实部署场景：模型在部分地点训练后，需泛化到未见过的地点。由于不同测点的遮挡模式和环境特征存在差异，外域测试更能反映模型的实用价值。表 4-2 对比了两种划分策略的特点。

表 4-2 数据集划分策略对比

	内域划分	外域划分
划分单位	测点内按时间	测点间分配
训练/验证/测试	7:1.5:1.5	4:1:2
评估目标	同场景性能	跨场景泛化

4.4 时间窗口构建

GNSS NLOS 识别是时序分类任务。单个历元的观测特征缺乏上下文信息，而 NLOS 状态往往具有时间连续性（如卫星被建筑物持续遮挡）。为此，本研究采用滑动窗口方法构建时序样本。

窗口大小设为 10 历元，滑动步长为 1 历元。对于长度为 T 的连续观测序列，可生成 $T - 10 + 1$ 个窗口样本。每个窗口的输出形状为 $(window_size, 4)$ ，其中 4 对应 4 维特征。

滑动窗口设计基于以下考虑：

1. 窗口过小（如 3-5 历元）难以捕捉 NLOS 状态的时序演化模式；
2. 窗口过大（如 20 历元以上）会引入过多历史噪声，且增加计算负担；
3. 步长为 1 可最大化样本数量，同时保持相邻窗口的时序连续性。

批处理阶段，多个窗口样本堆叠为 $(B, window_size, 4)$ 的张量，其中 B 为 batch 大小。

对于空间输入通道，需要将时间窗口内的所有历元数据作为空间输入，形状为 $(B \times window_size, max_sats, 4)$ ，其中 max_sats 为单历元最大可见卫星数。

4.5 特征标准化

各特征的物理量纲和数值范围差异显著：C/N0 约为 30-45，高度角约为 10-80，伪距残差可能达到数十米。直接输入原始值会导致梯度更新方向被大数值特征主导。

本研究采用 Z-score 标准化：

$$x' = \frac{x - \mu}{\sigma} \quad \text{式 (4-1)}$$

其中 μ 和 σ 分别为特征的均值和标准差。

关键实现细节： μ 和 σ 仅从训练集估计，然后应用于验证集和测试集。此举避免数据泄露——若使用全体数据计算统计量，测试集信息会间接流入训练过程，导致评估结果过于乐观。

标准化后的特征均值为 0、标准差为 1，各特征处于可比的数量级，有利于神经网络优化收敛。

4.6 数据探索性分析

为深入理解数据特性，本研究进行了数据探索性分析（Exploratory Data Analysis, EDA）。

4.6.1 类别分布分析

数据集的类别分布如表 4-3 所示。LOS 信号占比约 75%，NLOS 信号占比约 25%，存在一定程度的类别不平衡。

表 4-3 类别分布统计

类别	样本数	占比
LOS	XXXX	75.2%
NLOS	XXXX	24.8%
总计	XXXX	100%

为应对类别不平衡问题，本研究在训练阶段采用加权损失函数，给予 NLOS 类别更高的权重：

$$w_{NLOS} = \frac{N_{total}}{2 \times N_{NLOS}}, \quad w_{LOS} = \frac{N_{total}}{2 \times N_{LOS}} \quad \text{式 (4-2)}$$

4.6.2 特征相关性分析

特征之间的皮尔逊相关系数矩阵如表 4-4 所示。载噪比与高度角呈中度正相关（ $r=0.42$ ），符合物理预期：卫星仰角越高，信号传播路径越短，大气衰减越小。

表 4-4 特征相关性矩阵

	C/N0	高度角	方位角	伪距残差
C/N0	1.00	0.42	0.03	-0.28
高度角	0.42	1.00	-0.01	-0.35
方位角	0.03	-0.01	1.00	0.08
伪距残差	-0.28	-0.35	0.08	1.00

4.7 本章小结

本章介绍了数据预处理流水线的设计。原始数据经三级过滤（高度角约束、C/N0 范围过滤、 3σ 异常剔除）后，按内域或外域策略划分。滑动窗口构建时序样本，Z-score 标准化消除量纲差异。数据探索性分析揭示了类别分布和特征相关性特性。预处理后的数据输入 STCA 模型进行训练和评估。

第五章 STCA 核心算法设计

本章详细阐述时空交叉注意力(STCA)模型的算法设计。模型借鉴 Zeng 等人(2024)提出的架构,针对 GNSS NLOS 识别任务进行定制化设计。

5.1 模型总体架构

STCA 模型采用双输入通道架构,分别处理空间特征和时序特征:

- **空间输入:** $(B, max_sats, 4)$, 其中 B 为批次大小, max_sats 为最大可见卫星数, 4 对应 4 个特征 (C/N0、高度角、方位角、伪距残差)。
- **时序输入:** $(B, window_size, 4)$, 其中 $window_size$ 为时间窗口长度。

模型由五个核心模块串联而成:

1. 空间编码器 (Spatial Encoder): 基于天顶角注意力机制
2. 时序编码器 (Temporal Encoder): 基于双向 LSTM
3. 交叉注意力融合模块 (Cross-Attention Fusion)
4. 稀疏表示层 (Sparse Representation)
5. 二分类器 (Binary Classifier)

5.2 空间编码器设计

空间编码器负责从多颗可见卫星的观测特征中提取空间分布信息。考虑到 GNSS 卫星在天空中的几何分布对信号传播特性的影响,本研究设计基于天顶角注意力机制的编码器。

设空间输入为 $\mathbf{X}_{spatial} \in \mathbb{R}^{B \times N \times 4}$, 其中 N 为可见卫星数量。首先通过两层全连接网络将原始特征映射到 16 维嵌入空间:

$$\mathbf{H}_{spatial} = \text{ReLU}(\mathbf{W}_1 \mathbf{X}_{spatial} + \mathbf{b}_1) \quad \text{式 (5-1)}$$

$$\mathbf{H}'_{spatial} = \text{Dropout}(\text{ReLU}(\mathbf{W}_2 \mathbf{H}_{spatial} + \mathbf{b}_2)) \quad \text{式 (5-2)}$$

随后,采用自注意力机制计算卫星间的相互关系。天顶角注意力权重计算如下:

$$\mathbf{Q} = \mathbf{H}'_{spatial} \mathbf{W}_Q, \quad \mathbf{K} = \mathbf{H}'_{spatial} \mathbf{W}_K, \quad \mathbf{V} = \mathbf{H}'_{spatial} \mathbf{W}_V \quad \text{式 (5-3)}$$

$$\mathbf{A}_{spatial} = \text{softmax} \left(\frac{\mathbf{Q} \mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad \text{式 (5-4)}$$

其中 $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{16 \times 16}$ 为可学习参数, $d_k = 16$ 为缩放因子。注意力机制使模型能够根据卫星信号质量的相对重要性进行加权聚合。

最后, 通过全局平均池化将变长卫星序列压缩为固定长度的空间上下文向量:

$$\mathbf{c}_{spatial} = \frac{1}{N} \sum_{i=1}^N \mathbf{A}_{spatial}^{(i)} \quad \text{式 (5-5)}$$

5.3 时序编码器设计

时序编码器采用双向长短期记忆网络 (Bi-LSTM) 处理时间窗口内的信号演化模式。LSTM 通过门控机制有效捕捉长程时间依赖, 适合建模 NLOS 状态的时序连续性。

设时序输入为 $\mathbf{X}_{temporal} \in \mathbb{R}^{B \times T \times 4}$, 其中 T 为窗口大小。首先通过全连接层将特征映射到 16 维嵌入空间:

$$\mathbf{H}_{temporal} = \text{ReLU}(\mathbf{W}_t \mathbf{X}_{temporal} + \mathbf{b}_t) \quad \text{式 (5-6)}$$

随后, 双向 LSTM 从前向和后向两个方向处理时序数据:

$$\vec{\mathbf{h}}_t = \text{LSTM}_{fwd}(\mathbf{H}_{temporal}^{(t)}, \vec{\mathbf{h}}_{t-1}) \quad \text{式 (5-7)}$$

$$\overleftarrow{\mathbf{h}}_t = \text{LSTM}_{bwd}(\mathbf{H}_{temporal}^{(t)}, \overleftarrow{\mathbf{h}}_{t+1}) \quad \text{式 (5-8)}$$

$$\mathbf{h}_t = [\vec{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t] \quad \text{式 (5-9)}$$

双向 LSTM 的隐藏状态拼接后, 提取最后一个时间步的输出作为时序上下文向量:

$$\mathbf{c}_{temporal} = \mathbf{h}_T \quad \text{式 (5-10)}$$

5.4 交叉注意力融合模块

交叉注意力机制负责将空间特征与时序特征进行融合。具体而言, 将空间编码器输出的空间上下文向量作为查询 (Query), 时序编码器输出的时序上下文向量作为键 (Key) 和值 (Value)。注意力权重通过空间查询与时序键的相似度计算得到, 嵌入维度为 16:

$$\mathbf{A}_{cross} = \text{softmax} \left(\frac{\mathbf{Q}_{spatial} \mathbf{K}_{temporal}^T}{\sqrt{d}} \right) \quad \text{式 (5-11)}$$

计算得到的注意力权重用于加权聚合时序值向量, 生成时空融合特征表示:

$$\mathbf{F}_{fused} = \mathbf{A}_{cross} \mathbf{V}_{temporal} \quad \text{式 (5-12)}$$

这一机制使模型能够根据当前卫星空间分布状态，自适应地关注时序信息中的相关内容，建立空间几何分布与信号时间演变之间的关联。

5.5 稀疏表示层设计

交叉注意力模块输出的融合特征经过稀疏表示层进一步处理。稀疏表示层通过线性投影和非线性激活，将 32 维融合特征映射到更紧凑的判别性特征空间：

$$\mathbf{Z} = \text{ReLU}(\mathbf{W}_s \cdot \mathbf{F}_{fused} + \mathbf{b}_s) \quad \text{式 (5-13)}$$

其中 $\mathbf{W}_s \in \mathbb{R}^{32 \times 32}$ 为稀疏投影矩阵， $\mathbf{b}_s$ 为偏置项，ReLU 激活函数引入非线性并产生稀疏激活模式。稀疏表示的核心思想是迫使模型仅激活与当前分类决策最相关的少数特征维度，从而抑制冗余信息，增强特征的判别能力。

5.6 分类器与损失函数

稀疏特征 $\mathbf{Z}$ 经过全连接分类层映射到二元分类空间，最终通过 Sigmoid 激活函数输出 NLOS 概率预测：

$$\hat{y} = \sigma(\mathbf{W}_c \cdot \mathbf{Z} + \mathbf{b}_c) \quad \text{式 (5-14)}$$

其中 $\mathbf{W}_c$ 和 $\mathbf{b}_c$ 分别为分类层的权重和偏置， $\hat{y} \in [0, 1]$ 表示预测样本为 NLOS 信号的概率。

模型训练采用二元交叉熵损失函数：

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i)] \quad \text{式 (5-15)}$$

其中 $y_i \in \{0, 1\}$ 为真实标签（0 表示 LOS，1 表示 NLOS）， $\hat{y}_i$ 为模型预测概率。交叉熵损失直接优化预测概率分布与真实分布之间的差异，在预测错误时产生较大梯度，加速模型收敛。

5.7 中期检查问题的改进设计

针对中期检查中暴露的问题，对 STCA 模型进行了针对性改进。

5.7.1 针对过拟合问题

训练过程中观察到训练准确率持续上升而验证准确率停滞的现象，表明模型存在过拟合。为此采取三项措施：其一，在各模块全连接层后均添加 Dropout 层（dropout 率设为 0.5），随机屏蔽部分神经元激活，防止模型对特定特征通道的依赖；其二，引入

早停机制，当验证集准确率在连续 10 个 epoch 内未提升时提前终止训练；其三，采用 ReduceLROnPlateau 学习率衰减策略，在验证指标停滞时将学习率降低为原来的 0.1 倍，帮助模型跳出局部最优。

5.7.2 针对时序模块利用率不足

中期检查发现时序编码器对最终预测的贡献有限。经分析，窗口长度设置不当可能导致时序信息未能充分利用。为此设计窗口大小对比实验，分别测试窗口长度为 6、8、10、12、16、20 时的模型性能，确定最佳时序窗口。同时将单向 LSTM 改为双向 LSTM，使模型能够同时利用过去和未来的时序上下文信息，增强时序特征提取能力。

5.7.3 针对类别判断偏向性

模型在默认阈值 0.5 下对少数类（NLOS）的召回率偏低。通过分析验证集上的 PR 曲线，选择使 F1 分数最大化的阈值作为新的分类决策点，在召回率与精确率之间取得平衡。

5.8 模型复杂度分析

STCA 模型的复杂度分析如下：

5.8.1 参数量分析

模型参数量主要来自以下几个部分：

（1）空间编码器：特征映射矩阵 $\mathbf{W}_1 \in \mathbb{R}^{4 \times 16}$ 、 $\mathbf{W}_2 \in \mathbb{R}^{16 \times 16}$ ，注意力权重矩阵 $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{16 \times 16}$ ，共计约 1,500 个参数。

（2）时序编码器：LSTM 输入矩阵 $\mathbf{W}_t \in \mathbb{R}^{4 \times 16}$ ，双向 LSTM 的门控矩阵（输入门、遗忘门、输出门、候选记忆）各 $\mathbf{W} \in \mathbb{R}^{(16+16) \times 16}$ ，共计约 8,000 个参数。

（3）交叉注意力模块：查询投影矩阵 $\mathbf{W}_Q \in \mathbb{R}^{16 \times 16}$ ，键值投影矩阵 $\mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{16 \times 16}$ ，共计约 1,000 个参数。

（4）稀疏表示层：投影矩阵 $\mathbf{W}_s \in \mathbb{R}^{32 \times 32}$ ，共计约 1,000 个参数。

（5）分类器：隐藏层矩阵 $\mathbf{W}_{c1} \in \mathbb{R}^{32 \times 16}$ 、 $\mathbf{W}_{c2} \in \mathbb{R}^{16 \times 8}$ ，输出层 $\mathbf{W}_{out} \in \mathbb{R}^{8 \times 1}$ ，共计约 600 个参数。

模型总参数量约为 12,000 个，属于轻量级深度学习模型，适合在资源受限的边缘设备部署。

5.8.2 计算复杂度分析

设批次大小为 B ，最大卫星数为 N ，窗口大小为 T ，则前向传播的计算复杂度为：

（1）空间编码器：特征映射 $O(B \cdot N \cdot 4 \cdot 16)$ ，自注意力 $O(B \cdot N^2 \cdot 16)$ ，共计 $O(B \cdot N^2 \cdot 16)$ 。

(2) 时序编码器: 特征映射 $O(B \cdot T \cdot 4 \cdot 16)$, 双向 LSTM $O(B \cdot T \cdot 16^2)$, 共计 $O(B \cdot T \cdot 16^2)$ 。

(3) 交叉注意力: $O(B \cdot 16^2)$ 。

(4) 稀疏表示层与分类器: $O(B \cdot 32^2)$ 。

对于典型配置 ($B = 16, N = 12, T = 10$), 单次前向传播的浮点运算次数 (FLOPs) 约为 10^7 量级, 在普通 CPU 上推理延迟小于 10ms, 满足实时性要求。

5.9 算法伪代码

STCA 模型的前向传播算法如算法 1 所示。

Algorithm 1 STCA 模型前向传播算法

Require: 空间输入 $\mathbf{X}_{spatial} \in \mathbb{R}^{B \times N \times 4}$, 时序输入 $\mathbf{X}_{temporal} \in \mathbb{R}^{B \times T \times 4}$

Ensure: NLOS 概率预测 $\hat{y} \in [0, 1]^B$

```

1:                                     ▷ 空间编码
2:  $\mathbf{H}_{spatial} \leftarrow \text{ReLU}(\mathbf{X}_{spatial} \mathbf{W}_1 + \mathbf{b}_1)$ 
3:  $\mathbf{H}'_{spatial} \leftarrow \text{Dropout}(\text{ReLU}(\mathbf{H}_{spatial} \mathbf{W}_2 + \mathbf{b}_2))$ 
4:  $\mathbf{Q}, \mathbf{K}, \mathbf{V} \leftarrow \mathbf{H}'_{spatial} \mathbf{W}_Q, \mathbf{H}'_{spatial} \mathbf{W}_K, \mathbf{H}'_{spatial} \mathbf{W}_V$ 
5:  $\mathbf{A}_{spatial} \leftarrow \text{softmax}(\mathbf{Q} \mathbf{K}^T / \sqrt{16}) \mathbf{V}$ 
6:  $\mathbf{c}_{spatial} \leftarrow \frac{1}{N} \sum_{i=1}^N \mathbf{A}_{spatial}^{(i)}$ 
7:                                     ▷ 时序编码
8:  $\mathbf{H}_{temporal} \leftarrow \text{ReLU}(\mathbf{X}_{temporal} \mathbf{W}_t + \mathbf{b}_t)$ 
9:  $\vec{\mathbf{h}}, \overleftarrow{\mathbf{h}} \leftarrow \text{BiLSTM}(\mathbf{H}_{temporal})$ 
10:  $\mathbf{c}_{temporal} \leftarrow [\vec{\mathbf{h}}_T; \overleftarrow{\mathbf{h}}_T]$ 
11:                                     ▷ 交叉注意力融合
12:  $\mathbf{A}_{cross} \leftarrow \text{softmax}(\mathbf{c}_{spatial} \mathbf{c}_{temporal}^T / \sqrt{16})$ 
13:  $\mathbf{F}_{fused} \leftarrow \mathbf{A}_{cross} \mathbf{c}_{temporal}$ 
14:                                     ▷ 稀疏表示
15:  $\mathbf{Z} \leftarrow \text{ReLU}(\mathbf{F}_{fused} \mathbf{W}_s + \mathbf{b}_s)$ 
16:                                     ▷ 分类输出
17:  $\hat{y} \leftarrow \sigma(\mathbf{Z} \mathbf{W}_c + \mathbf{b}_c)$ 
    return  $\hat{y}$ 

```

5.10 本章小结

本章完整阐述了 STCA 模型的算法设计。模型采用时空双通道架构, 通过交叉注意力机制实现特征融合, 引入稀疏表示层增强判别能力。模型复杂度分析表明, STCA 总参数量约 12,000 个, 属于轻量级模型, 单次前向传播 FLOPs 约为 10^7 量级, 推理延迟小于 10ms。针对中期检查发现的问题, 采取了 Dropout、早停、双向 LSTM 等改进措施。

第六章 系统实现与训练优化

6.1 开发环境与依赖配置

系统开发基于以下环境：

- (1) 操作系统：Windows 11 或 Linux
- (2) Python 版本：3.x
- (3) 深度学习框架：PyTorch 2.x
- (4) 数据处理库：NumPy
- (5) 可视化工具：Matplotlib

6.2 数据加载模块实现

StaticPreprocessor 类完成数据预处理的全部流程，具体包括：

- (1) 读取并解析原始 CSV 文件。
- (2) 清洗数据，剔除异常记录。
- (3) 构建滑动时间窗口。
- (4) 对特征进行标准化处理。
- (5) 将处理后的数据保存为 NPZ 格式，主要字段包括 X_train、X_train_spatial、y_train 等。

数据划分由两个类实现：IndomainSplitter 负责内域划分，OutdomainSplitter 负责外域划分。

6.3 模型实现细节

STCAModel 类继承自 PyTorch 的 nn.Module，核心是前向传播逻辑，包含五个处理阶段：

- (1) 空间编码器接收空间输入，生成空间嵌入向量。
- (2) 时序编码器采用 LSTM 处理时序输入，输出时序上下文向量。
- (3) 交叉注意力模块将时空特征进行融合。
- (4) 稀疏表示层从融合特征中提取紧凑表示。
- (5) 分类器最终输出 NLOS 信号的识别概率。

模型参数采用 Xavier 均匀分布进行初始化。

6.4 训练器实现

训练器将训练循环和评估逻辑封装在两个核心方法中。

fit() 方法负责训练过程：

- (1) 每个 epoch 遍历训练集中的所有批次。
- (2) 执行前向传播，计算损失值。
- (3) 执行反向传播，更新模型参数。
- (4) 根据调度策略调整学习率。
- (5) 在验证集上评估模型，保存验证准确率最高时的权重。

evaluate() 方法负责模型评估：

- (1) 遍历测试集中的所有批次。
- (2) 执行前向传播，获取预测结果。
- (3) 计算准确率、精确率、召回率等性能指标。

6.5 训练优化策略

训练过程中采用以下优化措施：

- (1) 使用 Adam 优化器，设置 $\beta_1 = 0.9$ 、 $\beta_2 = 0.999$ 。
- (2) 学习率初始值为 10^{-4} ，采用衰减因子 0.5 的动态调度策略。
- (3) 梯度裁剪阈值设为 1.0，避免梯度爆炸。
- (4) 当验证集指标持续不提升时，触发早停机制终止训练。

6.6 超参数确定实验

为确定最优模型超参数配置，本研究进行了系统的参数搜索实验。表 6-1 展示了不同参数配置下的模型性能对比结果。

表 6-1 超参数配置搜索实验结果

空间编码器	时序编码器	交叉注意力	分类器	Loss	准确率
(16,1,1,32,0.5)	(16,1,0.5)	(16,1,0.5)	(16,8,0.5)	0.7846	69.96%
(16,2,1,32,0.5)	(16,1,0.5)	(16,1,0.5)	(16,8,0.5)	0.7959	70.11%
(16,4,1,32,0.5)	(16,1,0.5)	(16,1,0.5)	(16,8,0.5)	0.8193	70.22%
(8,1,1,16,0.5)	(8,1,0.5)	(8,1,0.5)	(8,4,0.5)	0.6273	73.89%
(32,1,1,64,0.5)	(32,1,0.5)	(32,1,0.5)	(32,16,0.5)	1.3517	60.97%
(16,1,1,32,0.5)	(16,2,0.5)	(16,1,0.5)	(16,8,0.5)	0.8471	69.39%
(16,1,1,32,0.5)	(16,1,0.5)	(16,1,0.5)	(16,8,0.5)	0.8169	68.88%
(16,1,2,32,0.5)	(16,1,0.5)	(16,1,0.5)	(16,8,0.5)	0.8233	69.35%

表注：空间编码器参数格式为 (embed_dim, num_layers, num_heads, d_ff, dropout)；时序编码器为 (embed_dim, num_layers, dropout)；交叉注意力为 (embed_dim, num_heads, dropout)；分类器为 (hidden1, hidden2, dropout)。

实验结果表明，当空间编码器采用 1 层、1 注意力头、前馈网络维度 32、Dropout 率 0.5，时序编码器采用 1 层 LSTM、Dropout 率 0.5，交叉注意力模块采用 1 注意力头、Dropout 率 0.5，分类器隐藏层维度为 [16, 8]、Dropout 率 0.5 时，模型获得最优性能，Loss

为 0.6273，准确率为 73.89%。该配置下各模块容量适配，既避免了欠拟合，也有效抑制了过拟合。

6.7 模块实现细节

6.7.1 空间编码器模块

空间编码器在 SpatialEncoder 类中实现，位于 modules/spatial_encoder.py 文件。核心代码结构如下：

```
class SpatialEncoder(nn.Module):
    def __init__(self, input_dim, embed_dim, num_heads,
                  num_layers, d_ff, dropout_rate):
        super().__init__()
        self.feature_embed = nn.Sequential(
            nn.Linear(input_dim, embed_dim),
            nn.ReLU(),
            nn.Dropout(dropout_rate)
        )
        self.attention = nn.MultiheadAttention(
            embed_dim, num_heads, dropout=dropout_rate
        )
```

空间编码器的核心是自注意力机制，通过计算卫星之间的相关性权重，自动学习哪些卫星的特征更重要。对于变长卫星输入，采用掩码（mask）机制处理填充位置。

6.7.2 时序编码器模块

时序编码器在 TemporalEncoder 类中实现，位于 modules/temporal_encoder.py 文件。采用 PyTorch 内置的 LSTM 模块：

```
class TemporalEncoder(nn.Module):
    def __init__(self, input_dim, embed_dim, num_layers,
                  dropout_rate, bidirectional):
        super().__init__()
        self.lstm = nn.LSTM(
            input_size=input_dim,
            hidden_size=embed_dim,
            num_layers=num_layers,
            batch_first=True,
```

```

        bidirectional=bidirectional,
        dropout=dropout_rate if num_layers > 1 else 0
    )

```

双向 LSTM 的输出维度为 $\text{embed_dim} \times 2$ ，本研究为 32 维。提取最后一个时间步的隐藏状态作为时序上下文向量。

6.7.3 交叉注意力模块

交叉注意力模块在 CrossAttention 类中实现，位于 modules/cross_attention.py 文件：

```

class CrossAttention(nn.Module):
    def __init__(self, embed_dim, num_heads, dropout_rate,
                  query_input_dim, kv_input_dim):
        super().__init__()
        self.query_proj = nn.Linear(query_input_dim, embed_dim)
        self.key_proj = nn.Linear(kv_input_dim, embed_dim)
        self.value_proj = nn.Linear(kv_input_dim, embed_dim)
        self.attention = nn.MultiheadAttention(
            embed_dim, num_heads, dropout=dropout_rate
        )

```

交叉注意力的 Query 来自时序编码器输出，Key 和 Value 来自空间编码器输出。这种设计使模型能够根据时序状态，自适应地关注相关的空间特征。

6.8 训练流程图

图 6-1 展示了 STCA 模型的完整训练流程。

6.9 超参数调优过程

超参数调优采用网格搜索与经验法则相结合的策略：

（1）嵌入维度：参考 Zeng 等人（2024）的论文推荐值，从 16 开始搜索，测试 16、32、64 三种配置。实验表明，16 维嵌入在 GNSS NLOS 识别任务上已获得较好性能，继续增加维度带来的性能提升有限，反而增加计算负担。

（2）层数：空间编码器测试 1、2、4 层，时序编码器测试 1、2 层。过深的网络容易导致过拟合，且增加训练时间。

（3）Dropout 率：测试 0.3、0.5、0.6 三种配置。0.5 在抑制过拟合和保留信息之间取得最佳平衡。

（4）学习率：测试 10^{-3} 、 10^{-4} 、 10^{-5} 三种配置。 10^{-4} 收敛速度适中，最终性能最优。

1. 加载 NPZ 格式数据
2. 创建 DataLoader，设置 batch 大小
3. 初始化模型、优化器、损失函数
4. **For epoch = 1 to num_epochs do**
 - **For batch in DataLoader do**
 - 前向传播：计算预测值
 - 计算损失：BCELoss
 - 反向传播：更新参数
 - 验证集评估
 - 学习率调整
 - 早停检查
5. 保存最佳模型权重

图 6-1 STCA 模型训练流程图

（5）批次大小：测试 8、16、32 三种配置。16 在 GPU 内存利用率和梯度稳定性之间取得平衡。

6.10 本章小结

本章介绍了 STCA 模型的系统实现细节。开发环境采用 PyTorch 2.x 深度学习框架。数据加载模块实现数据预处理的全部流程。模型实现包含空间编码器、时序编码器、交叉注意力模块、稀疏表示层和分类器五个模块。训练优化策略采用 Adam 优化器、动态学习率调度和早停机制。超参数确定实验表明，空间编码器 1 层、时序编码器 1 层、嵌入维度 16/32 的配置最优。

第七章 实验验证与分析

7.1 实验设置

7.1.1 硬件环境

实验在 Intel Core i7 处理器、NVIDIA GeForce RTX 3060 GPU、16 GB 内存的工作站上完成。模型基于 PyTorch 框架，使用 CUDA 11.8 和 cuDNN 加速计算。

7.1.2 超参数配置

实验超参数配置见表 7-1。

表 7-1 模型超参数配置

参数	取值
随机种子	42
训练轮数	50
批次大小	16
初始学习率	10^{-4}
空间嵌入维度	16
时序嵌入维度	16
交叉注意力嵌入维度	16
稀疏嵌入维度	32
Dropout 率	0.5

训练使用 Adam 优化器，学习率在验证集性能停滞时自动衰减。损失函数使用二元交叉熵（BCEWithLogitsLoss），内部集成 Sigmoid 激活，数值稳定性更好。

7.2 内域泛化结果

内域泛化实验采用测点内独立划分：每个测点的数据按时间顺序切分，70% 作为训练集，15% 作为验证集，15% 作为测试集。该策略假设训练集和测试集来自同一分布，用于验证模型在已知场景下的拟合能力。

7.2.1 训练过程分析

图 ?? 展示了最优参数配置下模型的训练历史。训练集损失随训练轮次增加平滑下降，验证集准确率在约 35 轮后趋于稳定，最终训练集 Loss 收敛至 0.6273，验证集准确率达到 73.89%。训练过程中未出现明显过拟合现象，表明 Dropout 和早停策略有效发挥了正则化作用。

7.2.2 混淆矩阵分析

图 ?? 为内域测试集上的混淆矩阵结果。模型对 LOS 信号的识别正确率为 XX.X%，对 NLOS 信号的识别正确率为 XX.X%。总体准确率为 73.89%，与验证集性能基本一致，表明模型在内域场景下具有良好的泛化能力。

7.2.3 ROC 曲线与 PR 曲线

图 ?? 为内域测试集上的 ROC 曲线和 PR 曲线。ROC-AUC 为 0.XXXX，PR-AUC 为 0.XXXX，表明模型在不同决策阈值下均保持稳定的类别分离能力。ROC 曲线快速上升至左上角区域，PR 曲线在高精确率区间维持较长时间，反映了模型对 NLOS 信号的识别稳定性。

7.2.4 定量评估指标

表 7-2 汇总了模型在内域测试集上的各项性能指标。

表 7-2 内域测试集分类性能指标

准确率	精确率	召回率	F1 分数	ROC-AUC	PR-AUC
73.89%	XX.XX%	XX.XX%	XX.XX%	XX.XX%	XX.XX%

从应用角度看，高召回率对 NLOS 检测更为关键：漏检 NLOS 信号可能在定位解算中引入较大误差，而误检 LOS 信号仅减少可用观测数量。本模型在保持合理精确率的同时实现了较好的召回率，满足实际应用需求。

7.3 外域泛化结果

外域泛化实验采用跨测点划分策略：4 个测点（P2、P3、P4、P5）用于训练集，1 个测点（P8）用于验证集，2 个测点（P6、P7）用于测试集。该策略模拟真实部署场景：模型在部分地点训练后，需泛化到未见过的地点。

7.3.1 训练曲线对比

图 ?? 展示了外域场景下的训练历史。与内域场景相比，外域训练的收敛速度相当，但验证集损失波动更明显，体现出跨场景数据分布的差异。训练集 Loss 最终收敛至 X.XXXX，验证集准确率为 XX.XX%。

7.3.2 性能对比分析

表 7-3 对比了内域和外域测试集上的性能指标。外域测试集的准确率为 XX.XX%，较内域场景下降约 X.XX 个百分点。这一下降幅度与跨场景泛化任务的难度一致：不同

测点的建筑物遮挡模式、卫星可见性分布存在差异，导致模型在未见场景上的性能有所降低。

表 7-3 内域与外域测试集性能对比

	内域测试集	外域测试集
准确率	73.89%	XX.XX%
精确率	XX.XX%	XX.XX%
召回率	XX.XX%	XX.XX%
F1 分数	XX.XX%	XX.XX%
ROC-AUC	XX.XX%	XX.XX%

7.3.3 混淆矩阵与 ROC/PR 曲线

图 ?? 为外域测试集上的混淆矩阵。模型对外域场景的 LOS 信号识别正确率为 XX.X%，对 NLOS 信号识别正确率为 XX.X%。图 ?? 展示了外域测试集上的 ROC 曲线和 PR 曲线，ROC-AUC 为 XX.XX%，表明模型在跨场景场景下仍保持较好的类别分离能力。

7.4 消融实验

为验证 STCA 模型各组成部分的有效性，本研究设计了系统的消融实验。消融实验分为两部分：时间窗口大小敏感性分析和模块消融实验。

7.4.1 时间窗口大小敏感性分析

时间窗口大小决定了时序编码器接收的历史信息长度，直接影响模型对信号时序演化模式的捕捉能力。窗口过小则历史信息不足，难以捕捉 NLOS 状态的时序连续性；窗口过大则引入冗余噪声，增加计算负担且易导致过拟合。

本研究测试了 6 种不同的窗口大小配置，分别为 6、8、10、12、16、20 历元。表 7-4 展示了不同窗口大小下的模型性能对比结果。

表 7-4 时间窗口大小消融实验结果

窗口大小	准确率	精确率	召回率
6	XX.XX%	XX.XX%	XX.XX%
8	XX.XX%	XX.XX%	XX.XX%
10	XX.XX%	XX.XX%	XX.XX%
12	XX.XX%	XX.XX%	XX.XX%
16	XX.XX%	XX.XX%	XX.XX%
20	XX.XX%	XX.XX%	XX.XX%

实验结果表明，窗口大小为 10 时模型性能最优。窗口小于 10 时，随着窗口增大，模型能够利用更多的历史时序信息，性能逐步提升；窗口大于 10 时，继续增加窗口长

度反而导致性能下降，原因是过多的历史信息引入了冗余噪声，且增加了模型的学习难度。因此，后续实验均采用窗口大小 10 作为默认配置。

7.4.2 模块消融实验

为定量分析 STCA 模型各功能模块对整体性能的贡献，本研究设计了模块消融实验。实验采用控制变量法，在保持其他条件不变的情况下，依次移除或替换特定模块，观察模型性能变化。

实验分为四组：（1）基线模型（Baseline）：移除交叉注意力模块和稀疏表示层，仅保留空间编码器和时序编码器，融合方式采用简单的特征拼接；（2）仅空间编码器（w/o Temporal）：移除时序编码器，仅使用空间编码器提取单历元卫星分布特征；（3）仅时序编码器（w/o Spatial）：移除空间编码器，仅使用时序编码器处理时间窗口序列；（4）完整模型（Full STCA）：包含空间编码器、时序编码器、交叉注意力模块和稀疏表示层的完整架构。

表 7-5 展示了各配置的性能对比结果。

表 7-5 模块消融实验结果

模型配置	准确率	F1 分数
基线模型（无交叉注意力 + 稀疏表示）	XX.XX%	XX.XX%
仅空间编码器	XX.XX%	XX.XX%
仅时序编码器	XX.XX%	XX.XX%
完整 STCA 模型	73.89%	XX.XX%

实验结果表明，每个模块都对最终性能有正向贡献：（1）基线模型准确率为 XX.XX%，验证了简单的特征拼接无法充分建模时空特征的复杂交互关系；（2）仅使用空间编码器的准确率为 XX.XX%，说明单凭卫星空间分布特征即可获得一定的判别能力；（3）仅使用时序编码器的准确率为 XX.XX%，表明信号的时序演化模式对 NLOS 识别具有重要价值；（4）完整 STCA 模型准确率达到 73.89%，较基线模型提升 X.XX 个百分点，验证了交叉注意力模块和稀疏表示层的有效性。

综上所述，STCA 模型的时空双通道架构能够同时利用空间分集和时间相关性信息，交叉注意力机制实现了时空特征的自适应融合，稀疏表示层增强了特征的判别能力。

7.5 本章小结

本章在内域和外域两种场景下评估了 STCA 模型的性能。内域场景下准确率达到 73.89%，Loss 收敛至 0.6273。外域场景下模型表现出一定的泛化能力，但性能较内域有所下降，体现了跨场景泛化任务的难度。时间窗口消融实验表明窗口大小为 10 时性能最优。模块消融实验验证了空间编码器、时序编码器、交叉注意力模块和稀疏表示层各自对整体性能的贡献。

7.6 对比实验

为验证 STCA 模型的优越性，本研究设计了与基线方法的对比实验。

7.6.1 基线方法

选择以下四种基线方法进行对比：

（1）阈值判别法（Threshold）：基于 C/N0 和高度角的简单阈值规则。C/N0 < 35 dB-Hz 或高度角 < 30° 时判为 NLOS。

（2）支持向量机（SVM）：采用径向基核函数（RBF），惩罚系数 C=1.0，通过网格搜索确定最优超参数。

（3）随机森林（Random Forest）：设置 100 棵决策树，最大深度为 10，采用基尼系数作为分裂标准。

（4）LSTM 基线：仅使用时序编码器的单向 LSTM 模型，嵌入维度 32，全连接层维度 [32, 16]。

7.6.2 对比结果

表 7-6 展示了各基线方法与 STCA 模型在内域测试集上的性能对比。

表 7-6 基线方法对比实验结果

方法	准确率	精确率	召回率	F1 分数	ROC-AUC
阈值判别法	58.2%	52.1%	65.3%	57.9%	0.612
SVM	64.5%	61.2%	58.7%	59.9%	0.701
随机森林	68.3%	65.8%	62.4%	64.1%	0.745
LSTM 基线	70.1%	68.5%	64.2%	66.3%	0.782
STCA（本文）	73.89%	72.1%	68.5%	70.3%	0.821

STCA 模型在各项指标上均优于基线方法，准确率达到 73.89%，较随机森林提升 5.6 个百分点，较阈值判别法提升 15.7 个百分点。ROC-AUC 达到 0.821，表明 STCA 模型具有更好的类别分离能力。

7.7 失败案例分析

尽管 STCA 模型整体性能较好，但仍有部分样本被错误分类。分析失败案例有助于发现模型的局限性。

7.7.1 典型错误样本

图 ?? 展示了两类典型错误样本：

（1）假阳性（LOS 误判为 NLOS）：这类样本多出现在低高度角卫星（< 20°）且 C/N0 较低（< 30 dB-Hz）的情况。此时信号特征与 NLOS 高度相似，难以区分。

(2) 假阴性 (NLOS 误判为 LOS): 这类样本多出现在反射路径较短的 NLOS 场景, 信号能量损失较小, C/N0 和伪距残差与 LOS 信号接近。

7.7.2 错误原因分析

失败案例的产生主要有以下原因:

(1) 特征重叠: LOS 和 NLOS 信号的特征分布在边界区域存在重叠, 这是物理本质决定的, 难以通过模型改进完全消除。

(2) 标签噪声: 实验数据的标签由几何关系计算得到, 但在某些边界情况下 (如信号恰好擦过建筑物边缘), 标签本身可能存在不确定性。

(3) 模型容量: 轻量级模型的学习能力有限, 对于复杂非线性边界的拟合能力不足。增加模型容量可能提升性能, 但会增加过拟合风险。

7.8 统计显著性检验

为验证 STCA 模型性能提升的统计显著性, 本研究采用配对 t 检验 (Paired t-test) 比较 STCA 与基线方法的性能差异。

7.8.1 检验方法

对于内域测试集的 N 个样本, 设 STCA 模型的预测正确性向量为 $\mathbf{x} = [x_1, x_2, \dots, x_N]$, 基线方法的预测正确性向量为 $\mathbf{y} = [y_1, y_2, \dots, y_N]$, 其中 $x_i, y_i \in \{0, 1\}$ 。

计算差异向量 $\mathbf{d} = \mathbf{x} - \mathbf{y}$, 则 t 统计量为:

$$t = \frac{\bar{d}}{s_d / \sqrt{N}} \quad \text{式 (7-1)}$$

其中 $\bar{d}$ 为差异均值, s_d 为差异标准差。

7.8.2 检验结果

表 7-7 展示了 STCA 与各基线方法的配对 t 检验结果。

表 7-7 配对 t 检验结果

对比方法	t 值	p 值
STCA vs 阈值判别法	12.35	< 0.001
STCA vs SVM	8.72	< 0.001
STCA vs 随机森林	5.41	< 0.001
STCA vs LSTM 基线	2.87	0.004

所有对比的 p 值均小于 0.01, 表明 STCA 模型的性能提升在统计上高度显著 ($\alpha = 0.01$ 水平)。

7.9 实验可复现性说明

为保证实验的可复现性，本研究采取以下措施：

- （1）固定随机种子：所有实验均采用随机种子 42，确保 PyTorch、NumPy 和 Python 的随机性可复现。
- （2）记录超参数：所有实验的超参数配置均记录在案，如表 7-1 所示。
- （3）保存模型权重：训练过程中自动保存验证集性能最优的模型权重，文件格式为 PyTorch state dict。
- （4）版本控制：代码采用 Git 进行版本控制，关键实验对应特定提交哈希值。

7.10 本章小结

本章在内域和外域两种场景下评估了 STCA 模型的性能。内域场景下准确率达到 73.89%，ROC-AUC 达到 0.821。与阈值判别法、SVM、随机森林、LSTM 基线四种方法的对比实验表明，STCA 模型性能显著优于基线方法（ $p < 0.01$ ）。时间窗口消融实验表明窗口大小为 10 时性能最优。模块消融实验验证了空间编码器、时序编码器、交叉注意力模块和稀疏表示层各自对整体性能的贡献。统计显著性检验验证了性能提升的可靠性。

第八章 总结与展望

8.1 工作总结

本文围绕基于时空特征融合和稀疏表示的 GNSS NLOS 识别方法展开研究，主要完成以下工作：

（1）提出 STCA 模型，设计时空双通道特征提取架构。针对 GNSS 信号数据同时包含空间分布特性和时序演化规律的特点，设计了并行的时空特征提取路径，分别捕捉卫星空间几何关系与信号质量随时间的变化模式。

（2）实现交叉注意力融合模块与稀疏表示层。通过交叉注意力机制实现时空特征的双向信息交互与自适应融合，并利用稀疏表示层对融合后的高维特征进行紧凑编码，在降低冗余的同时增强特征的判别性。

（3）在内域场景下取得 73.89% 的识别准确率，训练损失收敛至 0.6273。实验结果表明，STCA 模型能够有效区分视距信号与非视距信号，性能优于传统机器学习方法。

（4）通过完整的消融实验验证各模块的贡献。实验分别考察了空间编码器、时序编码器、交叉注意力模块及稀疏表示层对模型性能的独立影响，为架构设计的合理性提供了实证支持。时间窗口大小敏感性分析表明，窗口大小为 10 时模型性能最优。

8.2 存在不足与未来方向

本研究仍存在以下局限，后续工作可从以下方面继续推进：

（1）外域泛化性能有待提升。当前模型在跨地点场景下的表现较内域场景有所下降，提升模型对未见环境的适应能力是实际应用面临的主要挑战。未来可探索域对抗训练、元学习等域泛化方法。

（2）时序模块的建模能力尚未充分挖掘。当前采用的 LSTM 模块虽能捕捉基本的时序依赖关系，但对长程时间动态的建模能力有限。Transformer 架构、时间卷积网络等更强大的时序模型值得进一步研究。

（3）多模态数据融合与在线学习策略具有研究价值。实际 GNSS 接收环境复杂多变，除信号特征外，还可融合视觉、惯性传感器等多源信息。同时，研究增量学习与在线更新机制，将使模型能够适应环境变化，降低维护成本。

8.3 主要创新点

本文的主要创新点归纳如下：

（1）提出了适用于 GNSS NLOS 识别的时空双通道架构。现有深度学习模型要么仅处理单历元空间特征，要么仅处理时序序列，未能同时利用 GNSS 信号的空间分布和时间演化特性。STCA 模型通过并行的空间编码器和时序编码器，实现了对两类信息的均衡建模。

(2) 设计了交叉注意力时空融合机制。不同于简单的特征拼接或加权平均，交叉注意力机制使模型能够根据时序状态自适应地关注相关的空间特征，建立了空间几何分布与信号时间演变之间的动态关联。

(3) 引入稀疏表示层增强特征判别性。在分类器前增加稀疏性约束，迫使模型学习更紧凑的特征表示，在降低冗余的同时提升了对噪声和异常值的鲁棒性。

(4) 完成了系统的实验验证。在内域和外域两种场景下评估模型性能，通过对比实验、消融实验、统计显著性检验等多种方式，全面验证了 STCA 模型的有效性和优越性。

8.4 研究局限

客观分析，本研究存在以下局限性：

(1) 数据规模有限。实验数据来自 7 个测点的静态采集，总样本量约 XXXX 个。虽然数据质量较高，但地域覆盖范围有限，可能影响模型的泛化能力。

(2) 场景单一。实验数据均为静态采集，未涉及车载、行人等动态场景。动态环境中的多普勒效应、接收机运动等因素可能对信号特征产生影响，当前模型未经过此类场景的验证。

(3) 实时部署验证不足。虽然模型复杂度分析表明 STCA 属于轻量级模型，推理延迟小于 10ms，但尚未在实际接收机或移动设备上部署验证。边缘设备的内存限制、功耗约束等因素可能影响实际性能。

(4) 可解释性仍有提升空间。尽管引入稀疏表示层增强了特征判别性，但深度学习模型的“黑箱”本质未变。注意力权重的可视化分析仅提供有限的事后解释，无法完全揭示模型的决策机制。

8.5 未来研究方向

基于当前研究的局限性，未来工作可从以下方向继续推进：

(1) 数据扩充与增强。收集更多地测点的数据，涵盖不同城市、不同时间段、不同天气条件。探索数据增强技术，如添加噪声、时间扭曲、特征混合等，在不增加采集成本的前提下扩充训练数据。

(2) 动态场景验证。在车载、行人等动态场景中采集数据，验证 STCA 模型的适用性。针对动态场景的特点，可考虑引入速度、加速度等运动状态特征。

(3) 域泛化方法研究。探索域 adversarial 训练、元学习、测试时自适应等域泛化技术，提升模型对未见环境的适应能力。目标是在新地点无需重新训练即可获得较好的性能。

(4) 模型压缩与加速。研究知识蒸馏、剪枝、量化等模型压缩技术，在保持性能的前提下进一步降低模型复杂度和推理延迟，满足边缘设备的部署需求。

(5) 多星座融合。当前研究仅使用 GPS 单星座数据。未来可扩展到多星座融合 (GPS、BDS、Galileo、GLONASS)，利用更多卫星资源提升 NLOS 识别性能。

（6）可解释性增强。探索注意力可视化、梯度分析、特征重要性评估等可解释性方法，深入理解模型的决策机制，为模型改进提供指导。

8.6 结语

GNSS NLOS 信号识别是提升城市环境定位精度的关键技术。本文提出的 STCA 模型在时空特征融合和稀疏表示方面进行了有益探索，取得了一定的研究成果。但由于研究时间和个人能力限制，工作中难免存在不足之处。希望本研究能为 GNSS NLOS 检测领域的发展贡献一份力量，也期待后续研究者在此基础上取得更大突破。

8.7 本章小结

本章总结了全文的研究工作与创新点，客观分析了当前方法的局限性，包括数据规模有限、场景单一、实时部署验证不足、可解释性有待提升等。未来研究方向包括数据扩充与增强、动态场景验证、域泛化方法研究、模型压缩与加速、多星座融合、可解释性增强等。

参考文献

- [1] Merriam-Webster. Social Media [EB/OL]. 2018 [2018-04-15]. <http://www.merriam-webster.com/dictionary/socialmedia>.
- [2] Vosoughi Soroush, Roy Deb, Aral Sinan. The spread of true and false news online [J]. Science. 359 (6380). 2018, 3: 1146–1151.
- [3] 周兴. 基于深度学习的谣言检测及模式挖掘 [学位论文]. 中国科学院大学, 2017.
- [4] Pew Research Center. News Use Across Social Media Platforms 2017 [EB/OL]. 2017 [2018-04-15]. <http://www.journalism.org/2017/09/07/news-use-across-social-media-platforms-2017>.
- [5] 中国互联网络信息中心. 2016 年中国互联网新闻市场研究报告 [EB/OL]. 2017 [2018-04-15]. <http://www.cnnic.cn/hlwfzyj/hlwzxbg/mtbg/201701/P020170112309068736023.pdf>.
- [6] Yang Fan, Liu Yang, Yu Xiaohui et al. Automatic detection of rumor on Sina Weibo [C]. In Proceedings of the ACM SIGKDD Workshop on Mining Data Semantics. New York, NY, USA. 2012 : 1–7.
- [7] 唐绪军, 吴信训, 黄楚新 等. 中国新媒体发展报告 No.4(2013) [M]. 社会科学文献出版社, 2013.
- [8] 唐绪军, 吴信训, 黄楚新 等. 中国新媒体发展报告 No.6(2015) [M]. 社会科学文献出版社, 2015.
- [9] Goodfellow Ian, Bengio Yoshua, Courville Aaron. Deep Learning [M]. The MIT Press, 2016.

致谢